

논문 2022-59-5-7

전동기 기계시설물 고장 분류를 위한 이미지 인코딩 기반 경량화된 딥러닝 모델

(A Lightweight Deep Learning Model based on Image Encoding
for Failure Classification of Motor Mechanical Facilities)

안 동 주*, 신 재 광*, 이 수 안**

(Dongju An, Jaegwang Shin, and Suan Lee[©])

요 약

산업 현장에서 사용되는 전동기 기계 설비들의 고장은 베어링, 회전체, 벨트, 축이 상당 부분을 차지한다. 설비들이 기계적 또는 전기적 원인에 의해 고장이 발생하거나 성능이 저하되면 공통 적으로 진동이 발생하고 전류 등이 이상 움직임을 보인다. 이러한 상황에서 불특정하게 발생하는 고장을 쉽게 감지하고 예측하는 것은 필수적이다. 따라서 본 논문에서는 전동기 기계 설비에 부착된 센서에서 생성되는 시계열 데이터를 이미지로 인코딩하는 방법을 사용하여 경량화된 딥러닝 모델을 제안하였다. 이미지 인코딩에는 세 개의 방식을 사용하였고, 각각의 방식에 대한 CNN 기반 딥러닝 분류모델을 생성하였다. CNN 모델은 작은 파라미터를 가지면서도 제일 정확도가 높은 모델을 실험을 통해 만들었다. CNN 모델의 정확도를 분석하고 어떠한 인코딩 방식이 학습에 효율적이고 더 적합한지 실험해보았더니 세 개의 이미지 인코딩 방식 중에서도 GASF 방식이 대체로 정확도가 높게 나온 것을 확인하였다. 본 논문에서 제안한 이미지 인코딩 기반의 경량화된 딥러닝 모델을 이용해 산업에서 활용되는 여러 센서 데이터에 대해 다양한 응용에 활용할 수 있을 것이라 예상된다.

Abstract

The failure of mechanical facilities used in industrial sites accounts for a significant portion of bearings, rotators, belts, and axes. When facilities fail due to mechanical or electrical causes or performance degrades, vibration is commonly generated and current or the like shows abnormal movement. It is essential to easily detect and predict failures that occur unspecified in this situation. Therefore, in this paper, a lightweight deep learning model was proposed using a method of encoding time series data generated by a sensor attached to a mechanical facility into an image. Three methods were used for image encoding, and a CNN-based deep learning classification model was created for each method. The CNN model was created through experiments with the most accurate model with small parameters. When analyzing the accuracy of the CNN model and experimenting with which encoding methods are more efficient and suitable for learning, it was confirmed that the GASF method was generally more accurate among the three image encoding methods. It is expected that various sensor data used in the industry can be used for various applications using the lightweight deep learning model based on image encoding proposed in this paper.

Keywords : Timeseries classification, Image encoding, Deep learning, Lightweight model

I. 서 론

4차 산업혁명으로 최첨단 IoT 기술을 이용한 모니터링 및 인공지능 기술을 활용한 분류모델을 구축함으로써 국내외 관련 산업 생산성 증대 및 운영 분야 경쟁력 강화가 필요한 시점이다. 산업계 전반에 운용되는 기계 시설물의 고장으로 인한 안전관리 및 생산 활동 중단과 같은 기준에 불특정하게 고장이 발생한다. 이러한 고장

*학생회원, **정회원, 세명대학교 컴퓨터학부(School of Computer Science, Semyung University)

© Corresponding Author(E-mail : suanlee@semyung.ac.kr)

※ 본 과제(결과물)는 2021년도 교육부의 재원으로 한국연구재단의 지원을 받아 수행된 지 자체-대학 협력기반 지역혁신 사업의 결과입니다. 2021RIS-001(1345341783)

Received ; March 29, 2022

Revised ; April 5, 2022

Accepted ; April 5, 2022

W 의 각 열의 합을 1로 정규화함으로써 마르코프 전이 매트릭스를 구성할 수 있다. 이 과정에서 W 는 x 의 분포와 시간 인덱스 t_i 에 대한 시간 종속성이 제거된다. 이러한 W 의 정보 손실을 극복하기 위해, 시간 순서를 따라 각 확률을 정렬하여 MTF를 식 (4)와 같이 정의한다.

$$M = \begin{bmatrix} M_{11} & M_{12} & \cdots & M_{1n} \\ M_{21} & M_{22} & \cdots & M_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ M_{n1} & M_{n2} & \cdots & M_{nn} \end{bmatrix} \quad (4)$$

$$= \begin{bmatrix} w_{ij} & | & x_1 \in q_i, x_1 \in q_j \cdots w_{ij} & | & x_1 \in q_i, x_n \in q_j \\ w_{ij} & | & x_2 \in q_i, x_1 \in q_j \cdots w_{ij} & | & x_2 \in q_i, x_n \in q_j \\ \vdots & & \ddots & & \vdots \\ x_{ij} & | & x_n \in q_i, x_1 \in q_j \cdots w_{ij} & | & x_n \in q_i, x_n \in q_j \end{bmatrix}$$

MTF는 마르코프 전환 확률을 순차 적으로 표현하여 시간 영역에서 정보를 보존할 수 있다. 또한 적절한 임계값을 설정하여 딥러닝 학습 성능을 향상시킬 수 있다. 그림 2는 시계열 데이터를 마르코프 행렬로 계산하여 변환한 것이다.



그림 2. MTF의 변환 방법
Fig. 2. Conversion method of MTF.

2.3 RP(Recurrence Plot)^[6]

RP은 정사각형 행렬의 시각화 (또는 그래프)로, 행렬 요소가 동적 시스템의 상태가 반복되는 시간에 대응한다. 기술적으로, RP는 동적 시스템의 위상 공간 궤적이 위상 공간에서 거의 동일한 영역을 방문하는 모든 시간을 보여준다^[7]. RP는 다음과 같이 식 (5)로 나타낼 수 있다.

$$R_{i,j} = \Theta(\epsilon_i - \| \vec{x}_i - \vec{x}_j \|) \quad (5)$$

$$x_i \in R^m, \quad i, j = 1, \dots, N$$

RP를 사용하면 2차원 표현을 통해 m -차원 위상 공간 궤적의 특정 측면을 조사할 수 있다. 모든 조합의 거리 행렬을 기록한 것을 RP 행렬이라고 부른다. 그림 3은 회귀를 이용한 시계열 데이터를 RP를 이용해 이미지로 변환한 것이다. RP는 궤적의 회귀를 이용하기 때문에 시계열 데이터의 주기성 혹은 순간적으로 값이 크게

변하는 데이터에 대해서도 특정 정보를 잘 추출하고 궤적의 유사도에 따라 데이터 간의 연관성을 알 수 있다.




그림 3. RP의 변환 방법
Fig. 3. Conversion method of RP.

III. 이미지 인코딩 기반 기계시설물 고장 분류

본 논문에서는 단순하고 경량화된 모델에서도 기계 시설물의 고장 분류가 가능하도록 시계열 데이터의 이미지 인코딩 변환 과정을 수행한다. 기계시설물 데이터는 크게 축, 회전체, 베어링, 벨트 네 개로 구분되어 있고 데이터마다 정상과 비정상으로 구분되어 있다.

3.1 정상/축 정렬 불량 데이터와 이미지 인코딩

기계시설물 중에서 축에는 정상 97개, 축 정렬 불량 364개 파일로 이루어져 있다. 따라서 정상은 97초에 대한 194,000개, 축 정렬 불량은 364초에 대한 728,000개의 데이터로 이루어져 있다. 그림 4는 축에 대한 정상, 축 정렬 불량 샘플 데이터와 그 데이터를 GADF, GASF, MTF, RP 이미지 인코딩 방식을 적용했을 때의 결과이다.

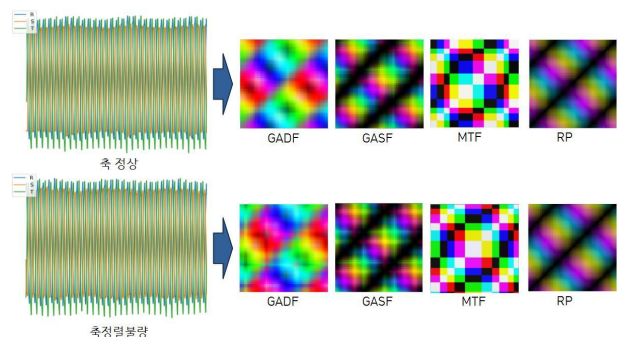


그림 4. 축에 대한 정상(위), 축 정렬 불량(아래) 샘플 데이터와 4개의 이미지 인코딩 결과
Fig. 4. Normal (top), axis misaligned (bottom) sample data and 4 image encoding results for axes.

3.2 정상/회전체 불평형 데이터와 이미지 인코딩

회전체에는 정상 667개, 회전체 불평형 229개 파일로 이루어져 있다. 따라서 정상은 667초에 대한 1,334,000

개, 회전체 불평형은 229초에 대한 458,000개의 데이터로 이루어져 있다. 그림 5는 회전체에 대한 정상과 회전체 불평형의 샘플 데이터와 그 데이터를 각각의 이미지 인코딩 방식을 적용했을 때의 결과이다.

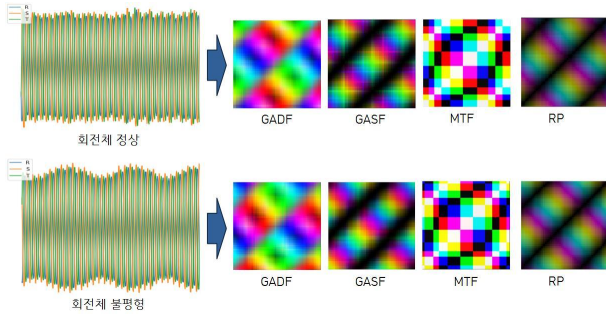


그림 5. 회전체에 대한 정상(위), 회전체 불평형(아래) 샘플 데이터와 4개의 이미지 인코딩 결과

Fig. 5. Normal (top) and unbalanced (bottom) sample data for a rotating body and 4 image encoding results.

3.3 정상/베어링 불량 데이터와 이미지 인코딩

베어링에는 정상 77개, 베어링 불량 200개 파일로 이루어져 있다. 따라서 정상은 77초에 대한 154,000개, 베어링 불량은 200초에 대한 400,000개의 데이터로 이루어져 있다. 그림 6은 베어링에 대한 정상, 베어링 불량 샘플 데이터와 그 데이터를 각각의 이미지 인코딩 방식을 적용했을 때의 결과이다.

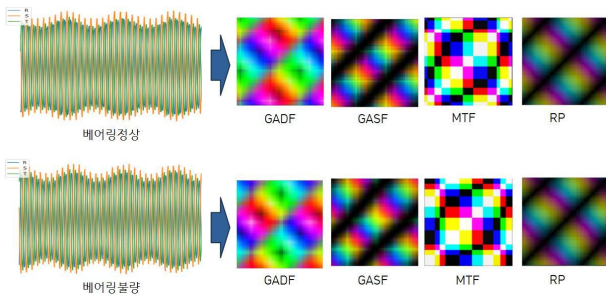


그림 6. 베어링에 대한 정상(위), 베어링 불량(아래) 샘플 데이터와 4개의 이미지 인코딩 결과

Fig. 6. Normal (top) and bad bearing (bottom) sample data and 4 image encoding results for bearings.

3.4 정상/벨트 느슨함 데이터와 이미지 인코딩

벨트에는 정상 65개, 벨트 느슨함 186개 파일로 이루어져 있다. 따라서 정상은 65초에 대한 130,000개, 벨트 느슨함은 186초에 대한 372,000개의 데이터로 이루어져 있다. 그림 7은 벨트에 대한 정상, 벨트 느슨함 샘플 데이터와 그 데이터를 각각의 이미지 인코딩 방식으로 적용한 결과이다.

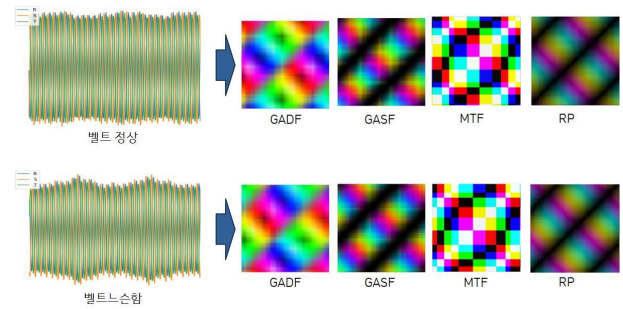


그림 7. 벨트에 대한 정상(위), 벨트 느슨함(아래) 샘플 데이터와 4개의 이미지 인코딩 결과

Fig. 7. Normal (top), belt slack (bottom) sample data and 4 image encoding results for the belt.

3.5 기계시설물 고장 분류를 위한 CNN 모델

본 논문에서 이미지 인코딩 기반의 기계시설물의 고장 분류를 위해서 CNN(Convolution Neural Network) 구조^[8]를 사용한다. 본 논문에서 사용하는 경량화된 CNN 모델의 구조는 특성 추출에 두 개의 컨볼루션 레이어(Convolution layer)와 하나의 맥스 풀링 레이어(Maxpool layer)로 이루어져 있고 분류에는 세 개의 완전연결층(Fully Connected layer)을 추가하고, 마지막 출력층 노드의 개수는 1개로 하며, 시그모이드(sigmoid) 활성화 함수를 사용하였다. 학습을 진행할 때의 손실 함수로는 Binary Cross Entropy 함수를 사용하였다. 입력받는 이미지의 크기는 (50, 50, 3)으로, 모델 학습 시 배치 크기는 32로 고정 하였다.

본 논문에서 이미지 인코딩의 변화에 따라 성능 비교를 위해 사용한 CNN 모델의 전체 구조는 표 1과 같다.

표 1. CNN의 구조(총 파라미터 수는 10,259,905개, 학습 가능한 파라미터 수는 10,259,905개임)

Table 1. Structure of CNN (total number of parameters is 10,259,905, number of Trainable parameters is 10,259,905).

Layer (type)	Output Shape	Parameter
Input_shape	(50, 50, 3)	-
Conv2D	(None, 50, 50, 32)	896
Conv2D	(None, 50, 50, 64)	18496
Max_Pool2D	(None, 25, 25, 64)	0
Dropout	(None, 25, 25, 64)	0
Flatten	(None, 40000)	0
Dense	(None, 256)	10240256
Dropout	(None, 256)	0
Dense	(None, 1)	257

IV. 실험

실험은 AIHub의 ‘전력 설비 에너지 패턴 및 고장 분석 센서’ 데이터를 사용하였다. 이 데이터는 크게 진동 데이터와 전류데이터로 구분되는데 본 논문에서는 전류 데이터를 사용하였다. 각 설비의 데이터에 대해 정상, 비정상 데이터끼리 합친 후 이미지 인코딩을 적용했고 정상 데이터와 비정상 데이터는 0, 1로 라벨링 하였고 각각의 데이터 세트의 크기가 달라서 각 설비의 모델을 따로 구성하였다.

시계열이라는 특성을 보존하기 위해서 이미지 크기는 (50, 50, 3)으로 고정하여 실험하였다. 이미지 인코딩을 하기 위해서는 데이터를 정규화하는 과정이 필수적이어서 최소-최대 정규화(min-max normalization)를 사용했다. 이미지 분류에는 이진 분류(binary classification) CNN을 사용하였다. 3가지의 이미지 인코딩 방식을 통해 어떠한 인코딩 방식이 효율적이고 좋은 결과가 도출되는지를 비교 실험하였다.

4.1 데이터 세트 구조

데이터 세트는 그림 8과 같이 수집된 데이터의 특성을 나타내는 메타 데이터(Meta Data) 영역과 수집된 데이터를 문자열로 변환하여 저장한 데이터(Data) 영역으로 구분되어 있다. 메타 데이터 부분은 데이터의 특성을 파악할 수 있도록 기계장치 특성과 데이터 특성을 이용하여 구성하였기 때문에, 사용자가 직접 원하는 파라미터를 추출할 수 있도록 구성이 되어있다. 데이터

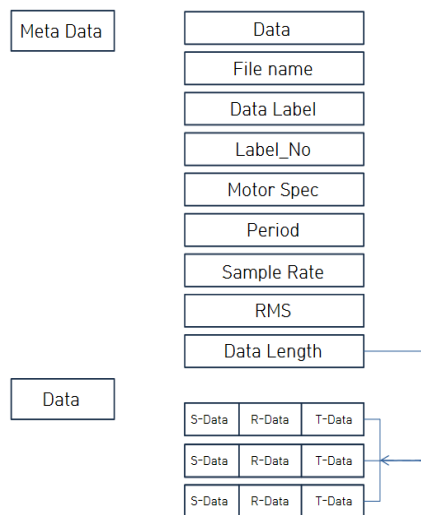


그림 8. 전류데이터의 구조
Fig. 8. Current data structure.

영역은 실제 수집된 데이터 값으로 본 논문에서 사용하는 전류데이터는 Time과 각 상(R, S, T)의 전류값으로 구성되어 있다.

데이터 세트에서 설비는 축, 회전체, 베어링, 벨트 네 개로 구성되어 있고 각각의 설비마다 정상, 비정상으로 구분되어 있다. 실질적인 데이터는 CSV 형태로 되어 있고 데이터의 구조는 (2000, 3)이다. 데이터 세트는 학습용 데이터(Train Data) 70%, 테스트 데이터(Test data) 20%, 검증 데이터(Validation data) 10%로 구성하였다.

4.2 비교 실험

본격적으로 각 이미지 인코딩을 통해 얻은 데이터를 CNN에 통과시킴으로써 어떠한 이미지 인코딩 방식이 설비의 고장탐지에 적합한지 살펴본다. 다음 표들은 GASF, GADF, MTF, RP 방식을 사용하여 설비들을 실험한 결과로, 각 알고리즘의 사용했을 때의 정밀도, 재현율, F1_score, 정확도를 측정한 것이다. 표 2는 기계 설비 중 베어링에 대한 딥러닝 모델의 성능지표를 측정한 것이다. 베어링 결과에서 정확도는 GASF 방식이 가장 높게 나온 것을 볼 수 있다. 정밀도는 GADF와 RP 이미지 인코딩 방식이 가장 높게 나왔고, 재현율과 F1_score, 정확도는 GASF 방식이 가장 높게 나온 것을 볼 수 있다.

표 2. 베어링의 정밀도, 재현율, F1_score, 정확도
Table 2. precision, recall, F1_score, accuracy for Bearings.

성능지표	GASF	GADF	MTF	RP
accuracy	0.998	0.996	0.763	0.998
precision	0.998	1.0	0.597	1.0
recall	0.999	0.995	0.388	0.993
f1_score	0.999	0.997	0.470	0.996

표 3은 기계 설비 중 회전체에 대한 딥러닝 모델에 대해 측정한 것이다. 정확도는 GASF 방식이 가장 높게 나왔지만, 정밀도와 재현율, F1_score는 RP 방식이 가

표 3. 회전체의 정밀도, 재현율, F1_score, 정확도
Table 3. precision, recall, F1_score, accuracy for Rotating body.

성능지표	GASF	GADF	MTF	RP
accuracy	0.983	0.953	0.752	0.982
precision	0.991	0.975	0.847	0.998
recall	0.986	0.982	0.191	0.993
f1_score	0.988	0.979	0.312	0.996

장 높게 나온 것을 알 수 있다.

표 4는 기계 설비 중 벨트의 딥러닝 모델에 대해 측정한 것이다. 정확도와 재현율은 GASF 방식이 가장 높았고, 정밀도는 RP 방식이 가장 높게 나온 것을 알 수 있다. GADF 방식은 F1_score가 높게 측정되었다.

표 4. 벨트의 정밀도, 재현율, F1_score, 정확도
Table 4. precision, recall, F1_score, accuracy for Belts.

성능지표	GASF	GADF	MTF	RP
accuracy	0.997	0.985	0.757	0.740
precision	0.984	0.996	0.593	1.0
recall	0.996	0.988	0.157	0.740
f1_score	0.990	0.992	0.248	0.851

표 5는 기계 설비 중, 축에 대한 딥러닝 모델을 측정한 것인데, 정확도와 F1_score는 GASF가 높게 나왔다. 정밀도는 RP 방식이 높았고, 재현율은 MTF 방식이 가장 높은 것을 알 수 있다. 실험 결과를 통해 GAF 알고리즘 중에서도 GASF가 대체 적으로 분류 성능이 가장 우수하다는 것을 확인할 수 있다.

표 5. 축의 정밀도, 재현율, F1_score, 정확도
Table 5. precision, recall, F1_score, accuracy for Axes.

성능지표	GASF	GADF	MTF	RP
accuracy	0.980	0.960	0.822	0.823
precision	0.993	0.978	0.761	1.0
recall	0.915	0.795	0.972	0.189
f1_score	0.948	0.877	0.854	0.317

그림 8은 GASF 방식으로 이미지 인코딩을 한 각 설비의 손실률과 정확도이다. 베어링과 벨트는 99.84%, 99.79% 이상의 정확도로 매우 우수하고, 회전체와 축도 98.03%, 98.33%로 우수한 결과를 보여주고 있다. 그러나 MTF 방식은 모든 설비의 정확도가 현저히 떨어진다. 이는 차이가 미세한 데이터들이 시간 종속성이 제거되는 과정에서 데이터 손실이 많이 일어난 것이 원인으로 보인다.

IV. 결 론

본 논문은 시계열 전류데이터의 이미지 인코딩을 통한 CNN 분류 방법을 제시하였다. 실험을 통해 3개의 이미지 인코딩 방법 중에서 GASF 방식이 CNN 모델의 분류 성능이 가장 우수함을 확인하였다. 본 실험으로

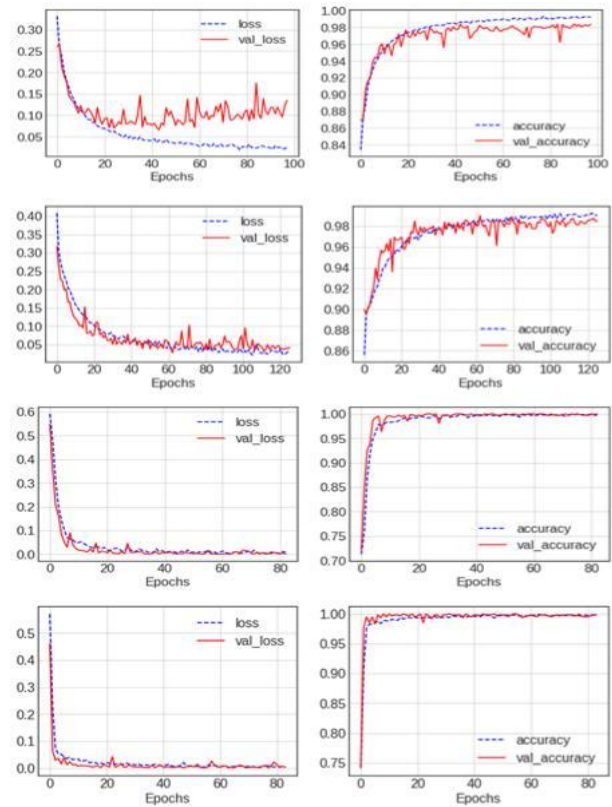


그림 9. 맨 위부터 GASF 이미지 인코딩 방식의 축, 회전체, 베어링, 벨트의 손실률과 정확도

Fig. 9. From top to bottom, GASF image encoding for axes, rotating bodies, bearings and belts loss rates and accuracy.

인해서 각 부품에서 발생하는 데이터를 기반으로 기기의 진단 및 상태를 예측하는 것이 필요하며, 이는 핵심 시스템의 관리 효율성 증대 및 안전사고를 예방하는 효과를 기대할 수 있고 기계 고장 시 빠른 대처를 통해 제품 불량, 교통 및 안전 서비스 정지 등으로 인한 불편과 사회적 혼란 등 2차 피해를 방지할 수 있다.

향후 과제로써는 전류데이터 이외의 진동 데이터도 실험하여 두 개의 결과를 합친 모델과 이미지로 인코딩할 때 데이터 손실을 줄이기 위한 전처리 방식과 변환이 필요하며, 경량화된 딥러닝 모델을 산업 현장에서 활용 가능하도록 AIoT 임베디드 장비에 적용시키는 연구를 수행할 계획이다.

REFERENCES

- [1] Introduction of failure prediction sensor for mechanical facilities, AIHub, last modified June 18, 2021, accessed April 26, 2022, <https://aihub.or.kr/aidata/30748>.


- [2] choiwonoung, Jaechan Cho and Yunho Jung. (2021). Design and Implementation of High-speed DTW Accelerator for Time-series Data Classification. Journal of the Institute of Electronics and Information Engineers, 58(3), 51-58.
- [3] Zhiguang Wang and Tim Oates. Imaging Time-Series to Improve Classification and Imputation. Proceedings of the 24th International Conference on Artificial Intelligence. July 2015
- [4] Liu, Lu & Wang, Zhiguang. (2016). Encoding Temporal Markov Dynamics in Graph for Time Series Visualization.
- [5] Jehn-Ruey Jiang and Cheng-Tai-Yen, Product Quality Prediction for Wire Electrical Discharge Machining with Markov Transition Fields and Convolutional Long Short-Term Memory Neural Networks, 25 June 2021
- [6] Marwan, N., Romano, M. C., Thiel, M., & Kurths, J. (2007). Recurrence plots for the analysis of complex systems. Physics reports, 438(5-6), 237-329.
- [7] Nima Hatami, Yann Gavet and Johan Debayle, Classification of Time-Series Images Using Deep Convolutional Neural Networks, 2017.
- [8] O'Shea, K., & Nash, R. (2015). An introduction to convolutional neural networks. arXiv preprint arXiv:1511.08458.

저 자 소 개



안 동 주(학생회원)
현재 세명대학교 컴퓨터 학부 재학

<주관심분야: 딥러닝, 컴퓨터 비전, 시계열 처리>



신 재 광(학생회원)
현재 세명대학교 컴퓨터 학부 재학

<주관심분야: 인공지능, 시계열 처리>



이 수 안(정회원)
2008년 강원대학교 컴퓨터과학과 학사 졸업
2010년 강원대학교 컴퓨터과학과 석사 졸업
2015년 (주)알티베이스 개발연구본부 연구원

2017년 강원대학교 컴퓨터과학과 박사 졸업
2019년 강원대학교 SW중심대학 연구교수/객원교수
2020년 인하대학교 VOICE AI 연구소 책임연구원
현재 세명대학교 컴퓨터학부 조교수

<주관심분야: 딥러닝, 머신러닝, 시공간, 그래프, 시계열>

